

A/B test - Who will win

Razdoblje testa: 2.-20. veljače 2024.

1. Motivacija

Who will win omogućuje korisnicima da glasaju koja će momčad pobijediti. U postojećoj verziji glas se nakon predaje ne može promijeniti. Pretpostavka je da bi Change Vote povećao angažman, jer korisnik može promijeniti glas nakon novih informacija. Korelacija nije dokaz uzročnosti, pa učinak provjeravamo A/B testom.

2. Hipoteza

- H0: nema razlike u angažmanu između kontrolne i treatment grupe.
- H1: postoji razlika u angažmanu.

Test je dvosmjernan, razina značajnosti 0,05.

3. Metrike

- Primarna: prosječan broj glasova po korisniku (broj event_vote po korisniku).
- Sekundarna: udio korisnika koji su glasali bar jednom (engagement rate).
- Guardrail: ukupna aktivnost po korisniku, Change Vote ne smije odvući korisnike od ostatka aplikacije.

4. Podaci

Izvor je tablica bq.events, kolona firebase_experiments. Kontrolna grupa je firebase_exp_84_0, treatment je firebase_exp_84_1. Platforma je android, razdoblje 2.-20. 2. 2024. Glavni event značajke je event_vote.

Budući da Change Vote djeluje tek nakon prvog glasa, primarnu metriku gledamo i samo na korisnicima koji su barem jednom glasali, no zaključak se ne mijenja.


Provjera podataka: 7 korisnika nalazilo se u obje grupe i izbačeni su iz analize. Omjer grupa značajno odstupa od očekivanih 50/50 (SRM): hi-kvadrat = 24,5 uz 1 stupanj slobode, $p < 0,001$.

Grupa	Verzija	Broj korisnika
Kontrolna (84_0)	bez Change Vote	19.551
Treatment (84_1)	s Change Vote	20.543

5. Test i rezultati

Korišteni testovi: two-proportion z-test za engagement rate i Mann-Whitney U test za broj glasova po korisniku (distribucija je asimetrična).

Metrika	Kontrolna	Treatment	Lift	p	Značajno?
Angažman (glasao bar jednom)	92,66%	92,98%	+0,35%	0,207	Ne
Glasova po korisniku	9,96	9,85	-1,13%	0,56	Ne



Oba 95% intervala pouzdanosti razlike sadrže nulu, pa razlika nije značajna. Angažman je već vrlo visok, oko 93%, pa ima malo prostora za rast, a Change Vote ionako djeluje tek nakon prvog glasa.

Ukupna aktivnost po korisniku nije pala u treatment grupi (oko 813 naspram 837 eventa po korisniku), pa Change Vote nije smanjio angažman s ostatkom aplikacije.

Snaga testa: uz oko 20.000 korisnika po grupi i baseline 93%, test je za engagement mogao sa snagom 80% detektirati razliku od oko 0,7 postotnih bodova. Kako je nije našao, null je vjerodostojan za promjene te veličine, dok vrlo male efekte ne možemo isključiti.

Vanjski faktori: u tom razdoblju veće utakmice mogu podizati broj glasova, no to jednako pogađa obje grupe pa ne iskrivljuje usporedbu.

6. Nedostajući analytics eventi

Event `event_vote` ne razlikuje prvi glas od promijenjenog, pa ne možemo izmjeriti stvarnu upotrebu. Mogući dodatak:

- `vote_change_click`: klik na gumb Change Vote (s parametrima `old_pick` i `new_pick`);.

7. Zaključak i preporuka

Change Vote je neutralan: angažman je ostao gotovo isti (s 92,7% na 93,0%, nije značajno), kao i broj glasova po korisniku (s 9,96 na 9,85, nije značajno), a guardrail aktivnost nije pala. Pouzdanost je ipak smanjena zbog SRM-a i toga što postojeći eventi ne mjere stvarnu upotrebu značajke.

Preporuka: ne raditi rollout na temelju ovih podataka. Prvo dodati namjenske evente pa ponoviti test kako bismo izmjerili stvarnu upotrebu i utjecaj na retenciju.